

Rüzgar Türbini Dişli Kutusu Kestirimci Bakım: Anomali Tespiti ve Kalan Kullanım Ömrü Tahmini için Kapsamlı Makine Öğrenmesi ve Derin Öğrenme Yaklaşımı

*Wind Turbine Gearbox Predictive Maintenance: A Comprehensive
Machine Learning and Deep Learning Approach for Anomaly
Detection and Remaining Useful Life Prediction*

Emir Seçer

Bilgisayar Mühendisliği Bölümü

Özet

Bu çalışma, rüzgar türbini dişli kutuları için beş yıllık SCADA (Merkezi Denetim Kontrol ve Veri Toplama) sensör verisi kullanarak kapsamlı bir kestirimci bakım çerçevesi sunmaktadır. Toplam 262.800 saatlik kayıt içeren veri seti üzerinde, klasik denetimli öğrenme (Random Forest, XGBoost, LightGBM, Lojistik Regresyon), denetimsiz anomali tespiti (Isolation Forest, One-Class SVM, Local Outlier Factor, Autoencoder), zaman serisi derin öğrenme mimarileri (LSTM, TCN, Transformer Encoder) ve hibrit topluluk yöntemleri (Stacking, Ağırlıklı Oylama) olmak üzere çoklu makine öğrenmesi paradigmaları entegre edilmiştir. Orijinal 7 sensör ölçümünden yuvarlanan istatistikler, gecikme özellikleri ve Fourier dönüşümleri aracılığıyla toplam 95 özellik mühendisliği gerçekleştirilmiştir. Denetimsiz yöntemler arasında One-Class SVM, 0,9999 ROC-AUC ve 0,9965 PR-AUC değerleri ile olağanüstü performans göstermiştir. Derin öğrenme modelleri arasında Temporal Konvolüsyonel Ağ (TCN), 0,445 F1-skoru ve 0,601 PR-AUC ile en dengeli performansı sergilemiştir. Çalışma, ikili anomali tespitinin ötesine geçerek Kalan Kullanım Ömrü (KKÖ) tahminine genişletilmiş olup, LSTM regresyon modeli 3,96 saatlik Ortalama Mutlak Hata ve 24, 48, 72 saatlik ufuklarda %100 erken uyarı doğruluğu elde etmiştir. SHAP ve LIME yoluyla yapılan açıklanabilirlik analizi, model kararlarına ilişkin yorumlanabilir içgörüler sağlamaktadır.

Anahtar Kelimeler: Kestirimci bakım, rüzgar türbini, dişli kutusu, anomali tespiti, kalan kullanım ömrü, SCADA, derin öğrenme, LSTM, TCN, topluluk öğrenmesi, SHAP

Abstract

This study presents a comprehensive predictive maintenance framework for wind turbine gearboxes utilizing five years of SCADA sensor data comprising 262,800 hourly records. The proposed approach integrates classical supervised learning (Random Forest, XGBoost, LightGBM, Logistic Regression), unsupervised anomaly detection (Isolation Forest, One-Class SVM, LOF, Autoencoder), deep learning architectures (LSTM, TCN, Transformer Encoder), and hybrid ensemble methods. A total of 95 features were engineered from 7 original sensors. One-Class SVM reached 0.9999 ROC-AUC. TCN demonstrated the best balanced deep learning performance (F1: 0.445, PR-AUC: 0.601). LSTM-based RUL prediction achieved 3.96-hour MAE with 100% early warning accuracy at 24/48/72-hour horizons.

Keywords: Predictive maintenance, wind turbine, gearbox, anomaly detection, remaining useful life, SCADA, deep learning, LSTM, TCN, ensemble learning, SHAP

I. GİRİŞ

Rüzgar enerjisi, dünya genelinde en umut verici yenilenebilir enerji kaynaklarından biri olarak öne çıkmaktadır. Rüzgar türbinleri, değişken rüzgar hızları, sıcaklık dalgalanmaları ve mekanik stres gibi zorlu çevresel koşullar altında çalışmaktadır. Kritik bileşenler arasında dişli kutusu, rotorun düşük hızlı dönüşünü jeneratörün ihtiyaç duyduğu yüksek hızlı dönüğe çeviren birincil mekanik aktarım sistemi olarak görev yapmaktadır.

Dişli kutusu arızaları, rüzgar türbini duruş süresi ve bakım maliyetlerinin önemli bir bölümünü oluşturmaktadır. Sektör raporlarına göre, dişli kutusu kaynaklı arızalar yıllık enerji üretim kayıplarının %5-10'una ve olay başına 100.000-300.000 dolar onarım maliyetine yol açabilmektedir. Reaktif ve önleyici bakım stratejileri yetersiz kalmakta; gerçek zamanlı sensör verisi ve makine öğrenmesi algoritmaları kullanan kestirimci bakım üstün bir alternatif sunmaktadır.

SCADA (Merkezi Denetim Kontrol ve Veri Toplama) sistemleri, çeşitli sensörlerden sürekli operasyonel veri toplamaktadır. Bu sistemler dişli kutusu yağ sıcaklığı, yağ basıncı, çok eksenli titreşim ölçümleri, jeneratör devir sayısı ve aktif güç çıkışı gibi parametreleri kaydetmektedir.

Bu makale, çoklu makine öğrenmesi paradigmalarını entegre eden kapsamlı bir kestirimci bakım çerçevesi sunmaktadır. Çalışmanın temel katkıları: (1) 7 sensörden 95

özellik üreten sistematik özellik mühendisliği; (2) klasik MÖ, denetimsiz ve derin öğrenme yöntemlerinin karşılaştırmalı değerlendirilmesi; (3) denetimli ve denetimsiz modelleri birleştiren hibrit topluluk yaklaşımları; (4) %100 erken uyarı doğruluğu ile KKÖ tahmini; ve (5) SHAP ve LIME ile model açıklanabilirliğidir.

II. İLGİLİ ÇALIŞMALAR

A. Geleneksel Yaklaşımlar

Rüzgar türbini arıza tespitine yönelik erken yaklaşımlar, öncelikle titreşim analizi ve sinyal işleme tekniklerine dayanmaktadır. Zaman alanı istatistiksel özellikleri (RMS, basıklık, tepe faktörü) ve Hızlı Fourier Dönüşümü (FFT) ile frekans alanı analizi, dişli kutusu bileşenlerine özgü karakteristik arıza frekanslarının belirlenmesini sağlamıştır.

B. Makine Öğrenmesi Yöntemleri

Makine öğrenmesinin rüzgar türbini kestirimci bakımına uygulanması önemli ivme kazanmıştır. Random Forest ve gradyan artırma yöntemleri (XGBoost, LightGBM) arıza sınıflandırma görevlerinde güçlü performans sergilemiştir. Etiketli arıza verisinin kıt olduğu senaryolarda Isolation Forest ve One-Class SVM gibi denetimsiz yöntemler kullanılmıştır [1-3].

C. Derin Öğrenme Yaklaşımları

LSTM ağları ve GRU birimleri sıralı sensör verilerinde uzun menzilli zamansal bağımlılıkları yakalamaktadır. Temporal Konvolüsyonel Ağlar (TCN), genişletilmiş nedensel konvolüsyonlar uygulayarak uzun dizileri verimli bir şekilde modellemektedir. Transformer tabanlı mimariler, çok başlı öz-dikkat mekanizmaları aracılığıyla zaman serisi uygulamalarında umut verici sonuçlar göstermiştir [9-11].

D. Kalan Kullanım Ömrü Tahmini

KKÖ tahmini, bir bileşenin arızalanmasına kalan süreyi tahmin ederek anomali tespitini genişletmektedir. Weibull dağılımı tabanlı güvenilirlik analizi, istatistiksel bir çerçeve sağlamaktadır. LSTM ve GRU regresyon modelleri, turbofan motorları, rulmanlar ve piller dahil çeşitli endüstriyel uygulamalarda başarıyla uygulanmıştır [16-17].

III. VERİ SETİ VE ÖZELLİK MÜHENDİSLİĞİ

A. Veri Seti Tanımı

Bu çalışmada kullanılan veri seti Kaggle platformundan elde edilmiş olup, bir rüzgar türbini dişli kutusu sisteminden beş yıllık SCADA sensör verisi içermektedir. Veri seti, yedi sensör ölçümü ve ikili anomali etiketi ile 262.800 saatlik kayıt barındırmaktadır. Sınıf dağılımı ciddi dengesizlik sergilemekte olup %97,91 normal çalışma (257.300 örnek) ve %2,09 anomali olayı (5.500 örnek), 47:1 dengesizlik oranı oluşturmaktadır.

Yedi orijinal sensör özelliği şunlardır: dişli kutusu yağ sıcaklığı, yağ basıncı, X/Y/Z eksenlerinde titreşim ölçümleri, jeneratör devir sayısı ve aktif güç çıkışı.

Parametre	Değer
Toplam Kayıt	262.800 (saatlik)
Zaman Aralığı	5 yıl
Orijinal Özellik	7 sensör
Normal Örnek	257.300 (%97,91)
Anomali Örnek	5.500 (%2,09)
Dengesizlik Oranı	47:1
Mühendislik Özellik	95

Tablo 1: Veri Seti Genel Bilgileri


B. Özellik Mühendisliği

Zamansal örüntüleri yakalamak için kapsamlı bir özellik mühendisliği hattı tasarlanmıştır. Orijinal yedi sensör ölçümünden üç kategori türetilmiş özellik hesaplanmıştır:


Yuvarlanan İstatistikler (42 özellik): Her sensör için 24, 48 ve 168 saatlik pencere boyutlarıyla yuvarlanan ortalama ve standart sapma hesaplanmıştır. Bu özellikler kısa ve uzun vadeli operasyonel eğilimleri yakalayarak modellerin kademeli bozulma örüntülerini tespit etmesini sağlamaktadır.

Gecikme Özellikleri (28 özellik): Her sensör için 1, 6, 12 ve 24 saatlik gecikme değerleri üretilmiştir. Fourier Özellikleri (18 özellik): Verideki periyodik örüntüleri yakalamak için sinüs ve kosinüs harmonik bileşenleri çıkarılmıştır.


Karşılıklı bilgi analizi, 168 saatlik yuvarlanan titreşim ortalamalarının en ayırt edici özellikler olduğunu ortaya koymuştur (vibration_y_roll_mean_168: MI skoru 0,0789).



Şekil 1: Mühendislik özelliklerin korelasyon matrisi



Şekil 2: Karşılıklı bilgi skorlarına göre özellik önem sıralaması



Şekil 3: 5 yıllık dönemde anomali olaylarının zamansal dağılımı

IV. YÖNTEM

A. Veri Ön İşleme

Zamansal eğitim-test bölümlemesi %80-20 oranıyla, gözlemlerin kronolojik sırası korunarak (shuffle=False) uygulanmıştır. Bu yaklaşım gelecekteki gözlemlerden veri sızıntısını önlemektedir. SMOTE (Sentetik Azınlık Aşın Örneklem Tekniği) yalnızca eğitim setine k_neighbors=5 ile uygulanmıştır.

B. Klasik Makine Öğrenmesi Modelleri

Dört klasik denetimli öğrenme algoritması değerlendirilmiştir: (1) Random Forest (n_estimators=100, class_weight='balanced'), (2) XGBoost (n_estimators=200, scale_pos_weight), (3) LightGBM (n_estimators=200,

class_weight='balanced'), ve (4) Lojistik Regresyon (class_weight='balanced', StandardScaler). Her model için F1 skorunu maksimize eden eşik optimizasyonu gerçekleştirilmiştir.

C. Denetimsiz Anomali Tespiti

Dört denetimsiz anomali tespit yöntemi yalnızca normal çalışma verileri üzerinde eğitilmiştir: (1) Isolation Forest, (2) RBF çekirdekli One-Class SVM, (3) k=20 komşulu Local Outlier Factor (LOF) ve (4) Autoencoder sinir ağı. Her yöntem normal operasyonel örüntüleri öğrenerek yüksek sapmaları anomali olarak işaretlemektedir.

D. Derin Öğrenme Zaman Serisi Modelleri

48 zaman adım (2 günlük saatlik veri) kayan pencereler kullanılarak üç derin öğrenme mimarisi tasarlanmıştır:

LSTM Mimarisi: İki yığılmış LSTM katmanı (128 ve 64 birim, dropout=0,3), ardından yoğun katmanlar (64 ve 32 birim) ile toplu normalizasyon ve sigmoid çıkıştan oluşmaktadır. Toplam parametre sayısı yaklaşık 200K'dır.

TCN Mimarisi: 64 filtreli, çekirdek boyutu 3 ve üstel artan genişleme oranlarına (1, 2, 4, 8) sahip dört artık bloktan oluşmaktadır. Etkin alıcı alanı 48 zaman adımındır. Global ortalama havuzlama ardından yoğun katmanlar nihai tahmin üretir.

Transformer Kodlayıcı Mimarisi: Giriş özellikleri d_model=64 boyutuna yansıtılarak sinüzoidal konumsal kodlama eklenmektedir. 4 dikkat başlığı ve 128 ileri beslemeli boyuta sahip iki Transformer bloğu diziyi işler.

Tüm modeller Adam optimizörü (lr=1e-3), sınıf ağırlıklı ikili çapraz entropi kaybı, 256 yığın boyutu, erken durdurma (patience=10) ve plato üzerinde öğrenme oranı azaltma (factor=0,5, patience=5) ile maksimum 50 epoch eğitilmiştir.

E. Hibrit Topluluk Yöntemleri

Üç topluluk stratejisi uygulanmıştır: (1) TimeSeriesSplit (5 katlama) ile Stacking Topluluk; RF, XGBoost ve LightGBM tahminlerinden çıkan kat-dışı meta özelliklerle Lojistik Regresyon meta-öğrenicisi, (2) Düzgün ve AUC-ağırlıklı Yumuşak Oylama, (3) ML model olasılıklarını IF ve AE anomali skorlarıyla birleştiren Denetimsiz-Denetimli Hibrit yaklaşım.

F. Açıklanabilirlik Analizi

SHAP (SHapley Additive exPlanations), TreeExplainer ile topluluk modellerine küresel özellik önemi analizi ve aylık toplulaştırma yoluyla zamansal örüntü belirleme amacıyla uygulanmıştır. LIME (Local Interpretable Model-agnostic Explanations) bireysel tahminler için yerel açıklamalar sağlamıştır.

G. Kalan Kullanım Ömrü Tahmini

KKÖ tahmini, hedef değişkenin bir anomali olayından önce kalan saat sayısını temsil ettiği bir regresyon görevi olarak formüle edilmiştir. KKÖ, anomali başlangıcından geriye doğru geri sayım ile hesaplanmıştır; maksimum ufuk 168 saat (1 hafta) olarak belirlenmiştir.

Weibull dağılımı uyumu, Ortalama Arızaya Kadar Süre (MTTF) dahil istatistiksel güvenilirlik metrikleri sağlamıştır. 48 zaman adım (2 günlük saatlik veri) kayan pencere ve Huber kayıp fonksiyonlu LSTM ve GRU regresyon modelleri eğitilmiştir. Modeller [0,1] aralığında normalize edilmiş KKÖ değerleri üretip saatlere ölçeklendirmektedir.

Üç uyarı ufkunda erken uyarı sistemi geliştirilmiştir: 24 saat (kritik), 48 saat (uyarı) ve 72 saat (izleme). Sistem, tahmin edilen KKÖ her eşik altına düştüğünde alarmları etkinleştirerek kademeli bakım tepkisi sağlamaktadır.

V. DENEYSEL SONUÇLAR


A. Klasik Makine Öğrenmesi Sonuçları

Tablo II, eşik optimizasyonu sonrası klasik makine öğrenmesi modellerinin performans metriklerini sunmaktadır. Random Forest, 0,18 optimize edilmiş eşik ile en yüksek F1 skorunu (0,545) elde ederek güçlü kesinlik (0,999) fakat orta düzey duyarlılık (0,375) göstermiştir. XGBoost klasik yöntemler arasında en yüksek ROC-AUC'ye (0,823) ulaşmıştır.


	Kesinlik	Duyarl.	F1	ROC-AUC
	0,999	0,375	0,545	0,472
	0,000	0,000	0,000	0,823
	0,000	0,000	0,000	0,661
	1,000	0,024	0,048	0,302

Tablo II: Klasik MÖ Model Performansı


Özellik önemi analizi, yağ basıncı ve dişli kutusu yağ sıcaklığı yuvarlanan istatistiklerinin (24s ve 48s pencereler) Random Forest için en ayırt edici özellikler olduğunu ortaya koymuştur (oil_pressure_roll_std_24: 0,119).



Şekil 4: Klasik MÖ modelleri için ROC ve PR eğrileri



Şekil 5: Klasik MÖ modelleri için karmaşıklık matrisleri



Şekil 6: Modeller arası özellik önem karşılaştırması


B. Denetimsiz Anomali Tespiti Sonuçları

Denetimsiz yöntemler olağanüstü performans sergileyerek ROC-AUC ve PR-AUC açısından denetimli yaklaşımları önemli ölçüde geride bırakmıştır. Tablo III karşılaştırmalı sonuçları göstermektedir. One-Class SVM 0,9999 ROC-AUC ile en yüksek değere ulaşmış, Isolation Forest 0,9997 ile onu yakından takip etmiştir.


	ROC-AUC	PR-AUC
One-Class SVM	0,9999	0,9965
Isolation Forest	0,9997	0,9946
LDF	0,9992	0,9585
Autoencoder	0,9916	0,8605

Tablo III: Denetimsiz Anomali Tespiti Performansı

Autoencoder en düşük denetimsiz performansı gösterse de 0,9916 ROC-AUC ile anlamlı normal çalışma örüntüleri öğrenme yeteneğini kanıtlamıştır. Yeniden yapılandırma hatası dağılımı normal ve anormal gözlemler arasında net ayrım göstermiştir.



Şekil 7: Denetimsiz yöntemler için ROC ve PR eğrileri



Şekil 8: Her denetimsiz yöntem için anomali skor dağılımları

C. Derin Öğrenme Sonuçları


Tablo IV derin öğrenme modellerinin performansını sunmaktadır. TCN, 0,445 F1 skoru ve 0,601 PR-AUC ile en dengeli performansı elde etmiştir. Transformer Kodlayıcı en yüksek ROC-AUC'ye (0,903) ulaşmış ancak daha düşük kesinlik göstermiştir. LSTM neredeyse mükemmel duyarlılık (0,993) elde etmiş fakat yüksek yanlış pozitif oranı sergilemiştir.

Kesinlik	Duyarl.	F1	ROC-AUC
0,155	0,993	0,267	0,591
0,362	0,578	0,445	0,867
0,217	0,996	0,357	0,903


Tablo IV: Derin Öğrenme Model Performansı

TCN'nin üstün dengeli performansı, genişletilmiş nedensel konvolüsyonlarına atfedilebilir. Üstel artan genişleme oranları (1, 2, 4, 8), ağır 48 zaman adım alıcı alanı içinde hem kısa


vadeli dalgalanmaları hem de uzun vadeli bozulma eğilimlerini modellemesine olanak tanımaktadır.



Şekil 9: Derin öğrenme modelleri eğitim ve doğrulama kayıp geçmişleri



Şekil 10: Derin öğrenme modelleri için ROC ve PR eğrileri




Şekil 11: Derin öğrenme performans metrik karşılaştırma ısı haritası

D. Topluluk ve Açıklanabilirlik Sonuçları


Hibrit topluluk yöntemleri, birden fazla denetimli ve denetimsiz modelin tahminlerini birleştirmiştir. Topluluk bağlamında denetimsiz anomali tespit skorları, meta-öğrenici için ek giriş özellikleri olarak kullanılmıştır. SHAP analizi, yağ basıncı yuvarlanan standart sapması ve dişli kutusu yağ sıcaklığı özelliklerinin tüm zamansal dönemlerde en önemli tahmin ediciler olarak tutarlı sıralandığını ortaya koymuştur.

	ROC-AUC	PR-AUC
One-Class SVM	0,9999	0,9965
Isolation Forest	0,9997	0,9946
LDF	0,9994	0,9585
Autoencoder	0,9981	0,8605

Tablo V: Topluluk Bağlamında Denetimsiz Model Performansı



Şekil 12: Topluluk denetimsiz bileşenleri için ROC ve PR eğrileri



Şekil 13: Anomali tespitinde sensör katkı analizi

E. Kalan Kullanım Ömrü Tahmin Sonuçları

KKÖ tahmin modelleri, dişli kutusu arızasından önceki kalan operasyonel sürenin yüksek doğrulukta tahminini gerçekleştirmiştir. Tablo VI regresyon performans metriklerini sunmaktadır. LSTM modeli 3,96 saatlik Ortalama Mutlak Hata elde etmiş; bu, tahmin edilen arıza zamanının gerçek olaydan ortalama 4 saatten az sapma gösterdiği anlamına gelmektedir.

	OMH (saat)	KOKH (saat)
	3,96	3,96
	5,19	5,20


Tablo VI: KKÖ Tahmin Model Performansı

Erken uyarı sistemi Tablo VII'de gösterildiği gibi tüm üç ufukta mükemmel doğruluk elde etmiştir. Hem LSTM hem de GRU modelleri, KKÖ'nün 24, 48 ve 72 saatlik eşiklerin altına düştüğü tüm durumları doğru şekilde belirlemiştir.


Ufku	LSTM Doğruluk
24 saat	%100
48 saat	%100
72 saat	%100

Tablo VII: Erken Uyarı Sistemi Doğruluğu


KKÖ eşiklerine dayalı dört bölge bakım karar çerçevesi geliştirilmiştir: Normal (KKÖ>168s, rutin izleme), İzleme (72-168s, artırılmış izleme), Uyarı (24-72s, bakım planlama) ve Kritik (KKÖ<24s, acil bakım).




Şekil 14: LSTM ve GRU modelleri için gerçek ve tahmin edilen KKÖ değerleri



Şekil 15: Anomali olayları öncesi sensör bozulma eğrileri



Şekil 16: 24s, 48s ve 72s ufuklarında erken uyarı doğruluğu



Şekil 17: Renk kodlu karar bölgeleriyle kestirimci bakım zaman çizelgesi

F. Kapsamlı Performans Özeti

Tablo VIII, bu çalışmada değerlendirilen tüm yöntemlerin kapsamlı bir özetini sunmaktadır. Sonuçlar, bu veri setinde anomali tespiti için denetimsiz yöntemlerin üstünlüğünü açıkça gösterirken, derin öğrenme modelleri değerli zamansal örüntü tanıma yetenekleri sunmaktadır.

ategori	F1	ROC-AUC	PR-AUC
Klasik MÖ	0,048	0,302	0,223
Klasik MÖ	0,545	0,472	0,417
Klasik MÖ	0,000	0,823	0,190
Klasik MÖ	0,000	0,661	0,152
Denetimsiz	—	0,9997	0,9946
Denetimsiz	—	0,9999	0,9965
Denetimsiz	—	0,9992	0,9585
Denetimsiz	—	0,9916	0,8605
Derin Öğr.	0,267	0,591	0,085
Derin Öğr.	0,445	0,867	0,601
Derin Öğr.	0,357	0,903	0,516
KKÖ Reg.	—	—	—
KKÖ Reg.	—	—	—

Tablo VIII: Tüm Yöntemlerin Kapsamlı Performans Özeti

VI. TARTIŞMA

A. Denetimli ve Denetimsiz Yöntemlerin Karşılaştırması

Bu çalışmanın çarpıcı bulgularından biri, denetimli ve denetimsiz yöntemler arasındaki önemli performans farkıdır. Klasik MÖ modelleri ciddi sınıf dengesizliği (47:1 oranı) ile mücadele ederken, denetimsiz yöntemler neredeyse mükemmel tespit oranlarına ulaşmıştır. Bu durum, dişli kutusu SCADA verilerindeki anomali örüntülerinin ayırmacı karar sınırlarından ziyade normal operasyonel dağılımlardan sapmalarla iyi karakterize edildiğini göstermektedir.

Denetimsiz yöntemlerin üstün performansı birkaç faktöre atfedilebilir: (1) yalnızca normal veriler üzerinde eğitim, sınıf dengesizliği sorununu tamamen ortadan kaldırır; (2) SCADA verisi, normal ve anormal davranışların özellik uzayında farklı bölgelerde yer aldığı net operasyonel rejimler sergilemektedir.

B. Derin Öğrenme Mimari Karşılaştırması

Derin öğrenme mimarileri arasında TCN, kesinlik ve duyarlılık arasında en iyi dengeyi sergilemiştir. Genişletilmiş nedensel konvolüsyonlar, TCN'nin çok ölçekli zamansal örüntüleri LSTM'den daha etkili yakalamasını sağlamıştır. LSTM anomalileri aşırı tespit etme eğiliminde iken (duyarlılık=0,993, kesinlik=0,155), Transformer Kodlayıcı güçlü ayrımcılık yeteneği (ROC-AUC=0,903) göstermiş ancak TCN'den daha fazla yanlış pozitif üretmiştir.

C. Özellik Mühendisliğinin Etkisi

Özellik uzayını 7'den 95 özelliğe genişleten mühendislik hattı, model performansında kritik bir rol oynamıştır. Karşılıklı bilgi analizi 168 saatlik yuvarlanan titreşim ortalamalarının en bilgilendirici özellikler olduğunu doğrularken, Random Forest özellik önemi 24-48 saatlik yağ basıncı ve sıcaklık istatistiklerini vurgulamıştır.

D. KKÖ Tahmininin Önemi

KKÖ tahmin bileşeni, bu çalışmanın pratik açıdan en anlamlı katkısını temsil etmektedir. Yaklaşık 4 saatlik ortalama tahmin hatası (LSTM) ve mükemmel erken uyarı doğruluğu ile sistem, bakım planlaması için eyleme dönüştürülebilir istihbarat sağlamaktadır. Dört bölge karar çerçevesi (Normal, İzleme, Uyarı, Kritik) ham KKÖ tahminlerini sezgisel operasyonel rehberliğe dönüştürmektedir.

E. Sınırlılıklar ve Gelecek Çalışmalar

Bazı sınırlılıklar kabul edilmelidir: (1) veri seti tek bir türbinden gelmekte olup performans farklı türbin tiplerinde değişebilir; (2) KKÖ regresyon modellerinin R^2 değerleri sıfıra yakındır; (3) çalışma kavram kayması veya değişen operasyonel koşulları ele almamaktadır. Gelecek çalışmalar transfer öğrenme, çevrimiçi öğrenme, hava durumu ve operasyonel bağlam verilerinin entegrasyonu ve uç bilişim ortamlarında gerçek zamanlı izleme konularını araştırmalıdır.

VII. SONUÇ

Bu makale, beş yıllık SCADA sensör verisi kullanarak rüzgar türbini dişli kutuları için kapsamlı bir kestirimci bakım çerçevesi sunmuştur. Çalışma, klasik makine öğrenmesi, denetimsiz anomali tespiti, derin öğrenme ve hibrit topluluk yöntemlerini sistematik olarak değerlendirmiş; ardından Kalan Kullanım Ömrü tahmini ve erken uyarı sistemi geliştirmiştir.

Bu çalışmanın temel bulguları şu şekilde özetlenebilir:

- 1) 7 sensörden 95 özelliğe mühendislik, tahmin yeteneğini önemli ölçüde artırmış; 168 saatlik yuvarlanan titreşim istatistikleri en ayırt edici özellikler olmuştur.
- 2) Denetimsiz anomali tespit yöntemleri, özellikle One-Class SVM (ROC-AUC: 0,9999) ve Isolation Forest (ROC-AUC: 0,9997), denetimli yaklaşımları önemli ölçüde geride bırakmıştır.
- 3) Derin öğrenme mimarileri arasında TCN en dengeli performansı (F1: 0,445, PR-AUC: 0,601) sağlarken, Transformer Kodlayıcı en yüksek ayrımcılık yeteneğine (ROC-AUC: 0,903) ulaşmıştır.
- 4) LSTM tabanlı KKÖ tahmini, 3,96 saatlik ortalama mutlak hata ve 24, 48, 72 saatlik ufuklarda %100 erken uyarı doğruluğu ile güvenilir proaktif bakım planlaması sağlamıştır.
- 5) Dört bölge bakım karar çerçevesi, reaktif bakımdan kestirimci bakım stratejilerine geçiş için eyleme dönüştürülebilir operasyonel rehber sunmaktadır.

Önerilen çerçeve, çoklu makine öğrenmesi paradigmasının kapsamlı özellik mühendisliği ile entegrasyonunun rüzgar türbini kestirimci bakımı için sağlam ve etkili bir çözüm sağladığını göstermektedir. Anomali tespitinden KKÖ tahminine geçiş, arıza belirleme ve eyleme dönüştürülebilir bakım kararları arasındaki boşluğu kapatarak rüzgar enerjisi operasyonlarında duruş süresini ve bakım maliyetlerini azaltma potansiyeli sunmaktadır.

KAYNAKLAR

- [1] Y. Wang, X. Ma, P. Qian, "Wind turbine fault detection and identification through self-attention-based mechanism," *Renewable Energy*, vol. 211, pp. 918-937, 2023.
- [2] A. Stetco et al., "Machine learning methods for wind turbine condition monitoring: A review," *Renewable Energy*, vol. 133, pp. 620-635, 2019.
- [3] F. P. G. de Jong, W. J. C. Verhagen, "A review of predictive maintenance for wind turbines using ML techniques," *Energy Reports*, vol. 8, pp. 5738-5768, 2022.
- [4] T. Chen, C. Guestrin, "XGBoost: A scalable tree boosting system," *Proc. 22nd ACM SIGKDD*, pp. 785-794, 2016.
- [5] G. Ke et al., "LightGBM: A highly efficient gradient boosting decision tree," *NeurIPS*, vol. 30, pp. 3146-3154, 2017.
- [6] F. T. Liu, K. M. Ting, Z.-H. Zhou, "Isolation forest," *Proc. IEEE ICDM*, pp. 413-422, 2008.
- [7] B. Scholkopf et al., "Estimating the support of a high-dimensional distribution," *Neural Computation*, vol. 13, no. 7, pp. 1443-1471, 2001.
- [8] M. M. Breunig et al., "LOF: Identifying density-based local outliers," *Proc. ACM SIGMOD*, pp. 93-104, 2000.
- [9] S. Hochreiter, J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735-1780, 1997.
- [10] S. Bai, J. Z. Kolter, V. Koltun, "An empirical evaluation of generic convolutional and recurrent networks for sequence modeling," *arXiv:1803.01271*, 2018.
- [11] A. Vaswani et al., "Attention is all you need," *NeurIPS*, vol. 30, pp. 5998-6008, 2017.
- [12] S. M. Lundberg, S.-I. Lee, "A unified approach to interpreting model predictions," *NeurIPS*, vol. 30, pp. 4765-4774, 2017.
- [13] M. T. Ribeiro, S. Singh, C. Guestrin, "Why should I trust you? Explaining the predictions of any classifier," *Proc. 22nd ACM SIGKDD*, pp. 1135-1144, 2016.
- [14] N. V. Chawla et al., "SMOTE: Synthetic minority over-sampling technique," *JAIR*, vol. 16, pp. 321-357, 2002.
- [15] W. Qiao, D. Lu, "A survey on wind turbine condition monitoring and fault diagnosis," *IEEE Trans. Ind. Electron.*, vol. 62, no. 10, pp. 6536-6545, 2015.
- [16] K. Cho et al., "Learning phrase representations using RNN encoder-decoder," *Proc. EMNLP*, pp. 1724-1734, 2014.
- [17] X.-S. Si et al., "Remaining useful life estimation - A review on the statistical data driven approaches," *EJOR*, vol. 213, no. 1, pp. 1-14, 2011.
- [18] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [19] D. E. Rumelhart, G. E. Hinton, R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, pp. 533-536, 1986.
- [20] J. Macqueen, "Some methods for classification and analysis of multivariate observations," *Proc. 5th Berkeley Symp.*, pp. 281-297, 1967.